



Artikel

Metode Berbasis Pembelajaran Mendalam untuk Mendeteksi Penyakit Padi Multikelas Menggunakan Citra Tanaman

Yuhai Li, Xiaoyan Chen*, Lina Yin dan Yue Hu

Fakultas Teknik Informasi, Universitas Pertanian Sichuan, Ya'an 625000, Tiongkok

* Korespondensi: chenxy@sicau.edu.cn

Abstrak: Diagnosis penyakit padi yang cepat dan akurat dapat mencegah wabah berskala besar dan mengurangi penggunaan pestisida secara berlebihan, sehingga memastikan hasil dan kualitas padi. Penelitian yang ada biasanya berfokus pada sejumlah kecil penyakit padi, yang membuat penelitian ini kurang dapat diterapkan pada berbagai macam penyakit yang saat ini menyerang padi. Akibatnya, penelitian ini gagal memenuhi kebutuhan deteksi pekerja pertanian. Selain itu, kurangnya pembahasan mengenai algoritma deteksi tingkat lanjut dalam penelitian saat ini membuat sulit untuk menentukan solusi aplikasi yang optimal. Untuk mengatasi keterbatasan ini, penelitian ini menyusun kumpulan data penyakit padi multikelas yang terdiri dari sebelas penyakit padi dan satu kelas daun sehat. Model yang dihasilkan lebih dapat diterapkan secara luas pada berbagai macam penyakit. Selain itu, kami mengevaluasi jaringan deteksi tingkat lanjut dan menemukan bahwa DenseNet muncul sebagai model dengan kinerja terbaik dengan akurasi 95,7%, presisi 95,3%, recall 94,8%, skor F1 95,0%, dan jumlah parameter hanya 6,97 M. Mempertimbangkan minat saat ini dalam pembelajaran transfer, studi ini memperkenalkan bobot yang telah dilatih sebelumnya dari kumpulan data ImageNet skala besar dan multikelas ke dalam eksperimen. Di antara model yang diuji, RegNet mencapai kinerja komprehensif terbaik, dengan akurasi 96,8%, presisi 96,2%, recall 95,9%, skor F1 96,0%, dan jumlah parameter hanya 3,91 M. Berdasarkan model RegNet berbasis pembelajaran transfer, kami mengembangkan aplikasi identifikasi penyakit padi yang menyediakan diagnosis penyakit padi yang sederhana dan efisien.

Kata Kunci: penyakit padi; multi-kategori; klasifikasi citra; transfer learning; RegNet



Kutipan: Li, Y.; Chen, X.; Yin, L.; Hu, Y. Metode Berbasis Pembelajaran Mendalam untuk Mendeteksi Penyakit Padi Multikelas Menggunakan Citra Tanaman. *Agronomi* **2024**; *14*, 1879. <https://doi.org/10.3390/agronomy14091879>

Editor Akademik: Richard Koech, Tej Bahadur Shahi dan Arjun Neupane

Diterima: 23 Juli 2024

Direvisi: 20 Agustus 2024

Diterima: 21 Agustus 2024

Diterbitkan: 23 Agustus 2024



Hak cipta: © 2024 oleh penulis. Pemegang lisensi MDPI, Basel, Swiss. Artikel ini merupakan artikel akses terbuka yang didistribusikan berdasarkan syarat dan ketentuan lisensi Creative Commons Attribution (CC BY) (<https://creativecommons.org/licenses/by/4.0/>).

1. Pendahuluan

Padi merupakan salah satu tanaman pangan terpenting di dunia, dengan luas areal tanam yang melebihi luas areal padi-padian utama lainnya. Akan tetapi, pertumbuhan dan perkembangan padi rentan terhadap penyakit. Penilaian dan penanganan penyakit sejak dini dapat mencegah penyebaran penyakit dan penyalahgunaan pestisida, sehingga dapat menjamin hasil dan kualitas padi. Oleh karena itu, mengidentifikasi penyakit padi secara akurat merupakan hal yang sangat penting bagi produksi padi.

Penyakit tanaman padi memiliki dampak yang signifikan terhadap perekonomian pertanian. Misalnya, ancaman global yang ditimbulkan oleh penyakit tanaman padi terhadap produksi dapat menyebabkan risiko keamanan pangan, yang berdampak pada banyak negara di Asia, Afrika, dan Eropa [1].

Metode tradisional untuk mendeteksi penyakit padi bergantung pada pengamatan petani yang berpengalaman, yang membutuhkan inspektur yang sangat terampil untuk mengidentifikasi ekspresi fenotipik berbagai penyakit. Namun, pendekatan ini memiliki keterbatasan, yang mengharuskan pengembangan metode deteksi lapangan yang lebih akurat dan cepat. Dengan kemajuan teknologi, penggunaan alat otomatis, termasuk drone, menjadi semakin umum di bidang pertanian. Misalnya, Perusahaan Teknologi XAG telah menunjukkan penggunaan drone untuk penyemaian padi secara langsung, membantu mengatasi kekurangan tenaga kerja di Tiongkok yang disebabkan oleh populasi yang menua dan pandemi COVID-19 [2]. Bahasa Indonesia: [3].

Subjek sasaran untuk aplikasi deteksi otomatis meliputi petani ladang dan drone otomatis. Misalnya, proyek Drones4Rice, yang diprakarsai oleh International Rice Research Institute (IRRI) dan Department of Agriculture—Philippine Rice Research Institute (DA-PhilRice), bertujuan untuk menetapkan protokol standar untuk aplikasi drone.

dalam produksi padi di Filipina. Hal ini menyoroti perlunya pertanian presisi dan praktik pertanian padi berkelanjutan. Motivasi di balik pengembangan aplikasi deteksi penyakit padi otomatis adalah untuk meningkatkan akurasi dan efisiensi deteksi penyakit, mengurangi kerugian ekonomi yang disebabkan oleh penyakit, dan mendorong transformasi digital pertanian. Metode tradisional untuk mendeteksi penyakit padi melibatkan ekstraksi fitur secara manual dan penggunaan teknik seperti pembelajaran mesin, mesin vektor pendukung, dan hutan acak untuk mengidentifikasi penyakit pada daun padi. Ahmed dkk. [4] mengusulkan sistem deteksi penyakit padi berdasarkan metode pembelajaran mesin, yang memerlukan masukan gambar daun dengan latar belakang putih. Dengan menggunakan metode pohon keputusan, sistem ini mencapai akurasi 97% dalam mengidentifikasi tiga penyakit padi: penyakit bulai hitam, penyakit busuk daun bakteri, dan bercak coklat. Pothen dkk. [5] memanfaatkan metode Otsu untuk melakukan segmentasi citra penyakit busuk daun bakteri, penyakit bercak hitam, dan bercak coklat. Mereka kemudian mengekstraksi fitur menggunakan Pola Biner Lokal (LBP) dan Histogram Gradien Berorientasi (HOG). Fitur-fitur tersebut diklasifikasikan menggunakan support vector machine (SVM) dengan kernel polinomial, yang mencapai akurasi 94,6%.

Jaringan saraf konvolusional arus utama saat ini tidak lagi bergantung pada ekstraksi fitur manual, tetapi mengekstraksi fitur melalui data berlabel dan sumber daya komputasi yang luas. Hasilnya, jaringan ini menunjukkan akurasi dan kemampuan generalisasi yang lebih baik [6]. Liang dkk. [7] mengusulkan metode pengenalan penyakit blas padi baru berdasarkan jaringan saraf konvolusional, yang menunjukkan bahwa fitur yang diekstraksi oleh jaringan saraf konvolusional lebih dapat dibedakan dan efektif dibandingkan dengan fitur buatan tangan tradisional. Metode ini mencapai akurasi pengenalan yang lebih tinggi. Jiang dkk. [8] pertama kali menggunakan jaringan saraf konvolusional (CNN) untuk mengekstraksi fitur dari gambar penyakit padi dan kemudian mengklasifikasikan dan memprediksi penyakit menggunakan metode SVM. Pendekatan ini mencapai akurasi 96,8% dalam mengidentifikasi empat jenis penyakit padi. Shah dkk. [9] membandingkan kinerja jaringan Inception V3, VGG16, VGG19, dan ResNet50 pada kumpulan data yang berisi dua kategori: penyakit blas pada padi dan daun sehat. ResNet50 menunjukkan kinerja terbaik dengan akurasi 99,75%. Mannepalli dkk. [10] menggunakan VGG16 untuk mengidentifikasi tiga penyakit padi: hawar daun bakteri, penyakit blas pada padi, dan bercak coklat. Pendekatan mereka mencapai akurasi klasifikasi 97,7% pada kumpulan data publik. Mohapatra dkk. [11] menggunakan model CNN mendalam untuk mengidentifikasi empat penyakit daun padi, yaitu bercak coklat, penyakit blas, penyakit hawar daun bakteri, dan penyakit Tungro, dengan tingkat akurasi mencapai 97,47%. Poorni dkk. [12] menggunakan model jaringan Inception V3 untuk mengidentifikasi tiga penyakit padi, yaitu hawar daun bakteri, bercak coklat, dan bercak daun bakteri, dengan tingkat akurasi sebesar 94,48%. Wang dkk. [13] mengusulkan model ADSNN-BO, yang menggabungkan jaringan MobileNet dan mekanisme augmented attention. Model ini mencapai akurasi 94,65% pada kumpulan data yang berisi empat kategori: bercak daun coklat sempit, kerusakan akibat hama padi, penyakit blas pada padi, dan daun sehat. Thai-Nghe dkk. [14] menggunakan jaringan EfficientNet untuk mengidentifikasi bercak coklat, penyakit blas pada padi, bercak coklat sempit pada daun, daun sehat, dan daun lainnya, dengan tingkat akurasi mencapai 95%. Mereka juga menerapkan model tersebut pada perangkat tertanam untuk aplikasi praktis. Lu dkk. [15] mengusulkan metode pengenalan penyakit padi berdasarkan jaringan saraf konvolusional dalam, yang mencapai akurasi pengenalan sebesar 95,4% pada kumpulan data 500 gambar daun padi, jauh lebih tinggi daripada model pembelajaran mesin tradisional. Rahman dkk. [16] menyempurnakan model besar seperti VGG16 dan InceptionV3 untuk mendeteksi hama dan penyakit padi serta memperkenalkan jaringan saraf konvolusional kecil untuk mendukung perangkat seluler. Dalam percobaan mereka, model ringan ini mencapai akurasi 93,3%.

Meskipun penelitian yang ada tentang identifikasi penyakit padi memiliki nilai yang signifikan, ada beberapa kekurangan. Pertama, kisaran penyakit padi yang diteliti dalam percobaan ini terbatas, sementara produksi padi dipengaruhi oleh berbagai macam penyakit. Model yang didasarkan pada kisaran penyakit yang terbatas tidak memiliki generalisasi yang diperlukan. Kedua, penelitian ini tidak membahas metode pengenalan tingkat lanjut saat ini, sehingga sulit untuk menentukan solusi deteksi yang optimal.

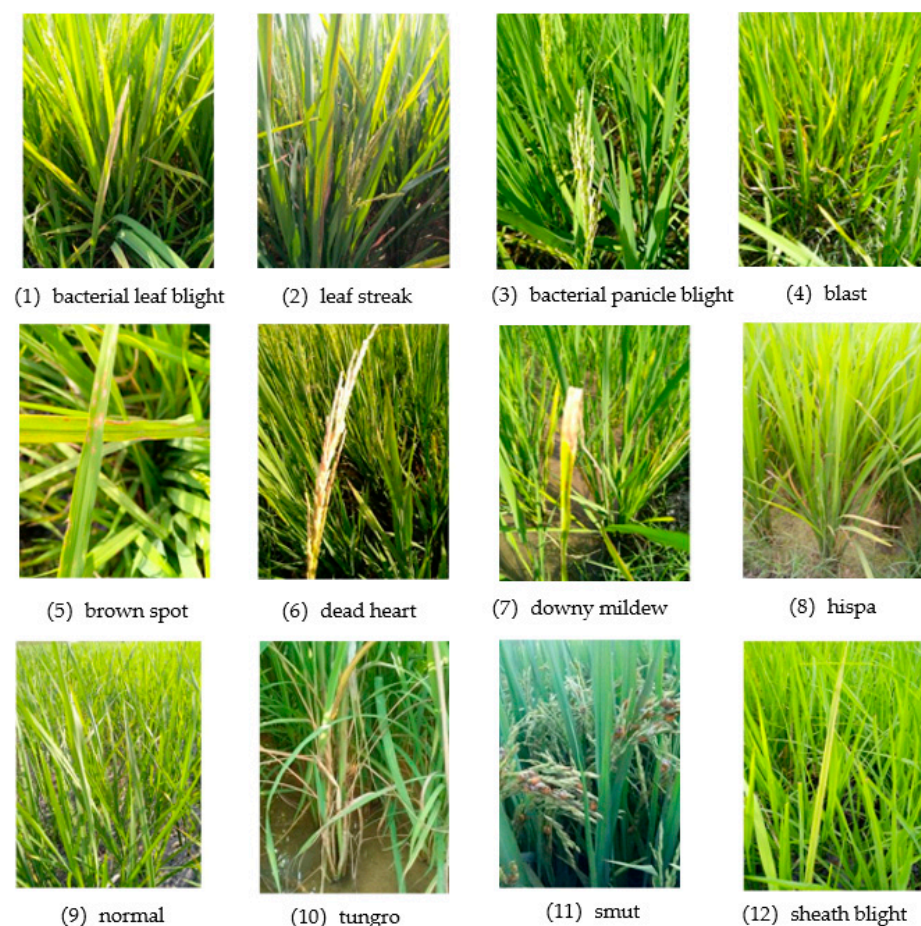
Untuk mengatasi masalah tersebut, penelitian ini telah menyusun dataset yang mencakup daun sehat dan 11 jenis penyakit padi untuk lebih mencerminkan kondisi penyakit yang ditemui selama pertumbuhan padi. Selain itu, makalah ini membahas kinerja jaringan klasifikasi citra canggih saat ini dalam mengidentifikasi beberapa kategori padi.

penyakit. Selain itu, agar lebih mudah diakses oleh masyarakat umum, penelitian ini mengembangkan aplikasi identifikasi penyakit padi yang dapat mendiagnosis penyakit padi secara sederhana dan efisien. Dengan membangun kumpulan data yang komprehensif dan membahas metode pengenalan tingkat lanjut, penelitian ini bertujuan untuk meningkatkan akurasi dan penerapan umum identifikasi penyakit padi. Aplikasi identifikasi yang dikembangkan diharapkan dapat memainkan peran penting dalam aplikasi praktis, memberikan dukungan teknis yang berharga untuk praktik pertanian.

2. Bahan dan Metode

2.1. Konstruksi Dataset

Dalam menyusun dataset, kami menggunakan dua metode: mengumpulkan gambar melalui mesin pencari dan memperoleh data dari platform Kaggle. Dataset penyakit padi yang dihasilkan mencakup 11 kategori penyakit padi dan 1 kategori daun sehat, dengan total 11.281 gambar. Kategori dalam dataset diilustrasikan dalam Gambar 1, dan jumlah gambar per kategori dirinci dalam Tabel 1. Dataset dibagi menjadi set pelatihan, validasi, dan pengujian, dengan rasio 60:20:20 (<https://www.kaggle.com/datasets/trumanrase/rice-leaf-diseases>, diakses pada 22 Juli 2024). Metode mesin pencari melibatkan pengunduhan gambar secara otomatis dengan memasukkan kata kunci ke Google menggunakan skrip Python. Gambar yang diunduh kemudian difilter dan dibersihkan untuk memastikan keakuratan data. Gambar untuk kategori penyakit bercak daun bakteri, Hispa, dan hawar pelepah padi semuanya bersumber dari mesin pencari.



Gambar 1. Contoh gambar dari setiap kategori dalam kumpulan data.

Penyakit hawar daun bakteri (HDB) merupakan penyakit padi yang disebabkan oleh bakteri *Xanthomonas oryzae* hal. *burung oryzae*, dan merupakan salah satu penyakit yang paling merusak dalam budidaya padi. BLB menyebabkan layunya daun padi secara luas, yang berdampak buruk pada fotosintesis, memperlambat pertumbuhan padi, dan menyebabkan pengisian gabah yang buruk, yang akhirnya mengakibatkan penurunan hasil panen padi secara signifikan. Dalam kasus yang parah, kehilangan hasil panen dapat mencapai 20–50% atau bahkan lebih tinggi [17]. Karena pesatnya

penyebaran penyakit ini, jika tidak dikendalikan sejak dini, BLB dapat dengan cepat menyebar ke seluruh lahan, dan menyerang semua tanaman padi. Benih yang terinfeksi merupakan salah satu jalur utama penularan BLB [18].

Tabel 1. Jumlah gambar per kategori dalam kumpulan data.

Indeks	Nama Penyakit	Gambar
1	Penyakit hawar daun bakteri	479
2	Garis daun bakteri	629
3	Penyakit hawar malai bakteri	337
4	Ledakan	tahun 1738
5	Bercak coklat	tahun 965
6	Hati Mati	tahun 1442
7	Penyakit bulai berbulu halus	620
8	Bahasa Spanyol	tahun 1594
9	Normal	tahun 1764
10	tungro	tahun 1088
11	Jelaga	373
12	Penyakit busuk daun padi	252

Penyakit garis daun bakteri merupakan penyakit padi yang disebabkan oleh *Xanthomonas oryzae* *oryzicola* (Xoc), yang memengaruhi fotosintesis daun padi. Penyakit bercak daun bakteri dapat menyebabkan kehilangan hasil hingga 40% hingga 60%, yang berdampak serius pada kuantitas dan kualitas produksi padi. Di Tiongkok, penyakit ini diklasifikasikan sebagai penyakit karantina yang penting, dan jangkauan geografisnya secara bertahap meluas. Faktor-faktor utama yang berkontribusi terhadap penyebarannya meliputi virulensi patogen, kerentanan tanaman inang, dan kondisi yang menguntungkan bagi perkembangan penyakit [19]. Penyakit bercak daun bakteri terutama ditularkan melalui angin, air, dan benih. Xoc dapat menyebar dari satu lahan ke lahan lain melalui angin atau air irigasi dan juga dapat menginfeksi benih, yang menyebabkan penularan jarak jauh [20].

Penyakit hawar malai bakteri merupakan penyakit padi parah yang disebabkan oleh *Burkholderia glumae*, yang menimbulkan ancaman signifikan terhadap produksi padi global. Penyakit ini menyebabkan berkurangnya tingkat pengisian gabah, perubahan warna, pembusukan, dan deformasi gabah, dengan potensi kehilangan hasil hingga 75% pada kasus yang parah [21]. Rute penularan utama meliputi benih yang terinfeksi dan jerami padi yang sakit sebagai sumber infeksi awal. Malai yang terinfeksi juga merupakan faktor kritis untuk infeksi sekunder, terutama selama seminggu sebelum dan setelah panen padi, yang merupakan periode paling rentan terhadap infeksi gabah [22].

Penyakit blas pada padi disebabkan oleh jamur *Pohon Magnaporthe oryzae*, merupakan penyakit penting yang menimbulkan ancaman serius terhadap hasil panen dan kualitas padi. Penyakit ini dapat terjadi sepanjang masa pertumbuhan padi, yang menyebabkan berbagai tingkat kehilangan hasil panen. Dalam kasus yang parah, penurunan hasil panen dapat berkisar antara 40% hingga 50%, atau bahkan mengakibatkan gagal panen total. Rute penularan utama penyakit blas pada padi meliputi benih yang terinfeksi dan jerami padi yang sakit sebagai sumber awal infeksi [23]. Konidia dan miselia patogen dapat bertahan di jerami padi yang tertinggal di ladang atau di bulir padi, masuk ke tanah bersama benih setelah disemai, sehingga menjadi sumber infeksi. Dalam kondisi lingkungan yang mendukung, patogen terus-menerus menghasilkan spora, yang disebarkan oleh angin ke tanaman padi, menyebabkan infeksi dan produksi spora lebih lanjut, yang menyebabkan siklus infeksi berulang.

Bercak coklat, disebabkan oleh jamur *Bipolaris oryzae*, merupakan penyakit padi yang menyerang daun tanaman padi dan memiliki distribusi global. Meskipun bercak coklat terutama menyerang daun, penyakit ini juga dapat menyerang gabah, batang, dan kulit padi [24]. Daun yang terinfeksi akan membentuk lesi melingkar atau elips yang mengganggu fotosintesis, melemahkan pertumbuhan dan perkembangan tanaman, serta menyebabkan tanaman padi kerdil dan menua sebelum waktunya, yang pada akhirnya mengurangi hasil panen. Cara penularan utama bercak coklat adalah melalui benih yang terinfeksi.

Penyakit Jantung Mati biasanya terjadi selama tahap pembibitan atau anakan pada pertumbuhan padi, yang terutama bermanifestasi sebagai layu dan menguningnya daun bagian tengah, yang akhirnya menyebabkan kematian tanaman. Tanaman padi yang terinfeksi Penyakit Jantung Mati menunjukkan pertumbuhan terhambat, anakan berkurang, dan pada kasus yang parah, tanaman mati total, yang secara signifikan

Penyakit ini biasanya ditularkan oleh hama seperti penggerek batang padi (*Chilo suppressalis*) atau penggerek batang kuning (*Scirpophaga incertulas*), yang menyebarkan patogen penyebab penyakit dengan memakan batang atau pelepah daun tanaman padi.

Penyakit bulai berbulu merupakan penyakit yang disebabkan oleh jamur *Peronosclerospora* spesies, terutama menyerang padi selama tahap pembibitan. Tanaman padi yang terinfeksi biasanya menunjukkan gejala seperti daun menguning, layu, dan pertumbuhan terhambat, dengan kasus yang parah berpotensi menyebabkan kematian tanaman. Penyebaran penyakit bulai terutama terjadi melalui sisa-sisa tanaman yang terinfeksi, tanah, dan spora yang terbawa udara [25].

Penyakit Hispa terutama disebabkan oleh kumbang beras Hispa (*Dicladispa armigera*). Penyakit ini terutama merusak tanaman padi melalui kumbang dewasa yang memakan jaringan epidermis daun padi. Daun yang terinfeksi menunjukkan garis-garis lesi putih, yang secara bertahap berubah menjadi cokelat dan dapat menyebabkan pengeringan daun. Penyebaran penyakit Hispa terutama terjadi melalui terbangnya kumbang dewasa [26].

Penyakit tungro merupakan penyakit kompleks yang disebabkan oleh infeksi virus tungro basiliform padi (RTBV) dan virus tungro bulat padi (RTSV). Penyakit ini berdampak parah pada tanaman padi, menyebabkan pertumbuhan terhambat, daun menguning dengan garis-garis kuning kehijauan yang khas, dan berkurangnya jumlah anakan. Tanaman yang terinfeksi menunjukkan penurunan yang signifikan pada jumlah anakan, malai, dan gabah [27]. Penyebaran penyakit Tungro terutama bergantung pada serangga vektor seperti wereng hijau (*Bunga Nephrotettix virescens*) dan wereng zigzag (*Nephrotettix cincticeps*). Serangga ini menularkan virus ke tanaman sehat setelah memakan getah tanaman padi yang terinfeksi [28].

Penyakit busuk daun padi merupakan penyakit yang disebabkan oleh jamur *Ustilagoideae vires*. Penyakit ini menyebabkan terbentuknya "bola-bola jamur" yang lebih besar pada beberapa bulir padi, yang tidak berkembang dengan baik, sehingga mengakibatkan berkurangnya hasil panen padi. Jamur tersebut menghasilkan racun seperti ustiloksin, yang dapat berbahaya bagi hewan dan manusia, serta berpotensi memengaruhi kesehatan jika dikonsumsi dalam jangka panjang. Spora jamur tersebut terutama disebarkan oleh angin, dengan tahap pembentukan dan pembungaan padi yang paling rentan terhadap infeksi [29].

Penyakit busuk pangkal batang padi merupakan penyakit padi yang serius yang disebabkan oleh jamur *Rhizoctonia solani*. Penyakit ini mengakibatkan kerusakan pada batang dan pelepah tanaman padi, sehingga mempengaruhi fotosintesis dan selanjutnya mengurangi hasil gabah. Patogen dapat menyebar melalui air irigasi di sawah, di mana aliran air dapat menyebarkan patogen ke tanaman lain [30]. Bahasa Indonesia: [31].

2.2. Parameter Pelatihan Platform Eksperimental

Lingkungan eksperimen untuk model dalam penelitian ini dirinci dalam Tabel 2. Semua algoritme diuji dalam kondisi yang sama. Pelatihan jaringan dilakukan menggunakan pengoptimal Adam dengan laju pembelajaran 0,0001, ukuran batch 16, dan 4 utas bersamaan, yang diulang 100 kali. Fungsi kerugian entropi silang digunakan. Eksperimen dilakukan pada mesin yang menjalankan sistem operasi Windows 10, dengan prosesor E5-2690 v4 26-utas, prosesor grafis 3060Ti dengan VRAM 8 GB, dan RAM 32 GB.

Tabel 2. Tabel konfigurasi lingkungan eksperimen.

Konfigurasi	Parameter
prosesor	CPU Intel(R) Xeon(R) E5-2690 v4
GPU	NVIDIA GeForce RTX 3060 Ti, VRAM 8192 MB
Sistem operasi	Jendela 10
Lingkungan akselerasi CUDA	2.0.1+cu117
Ular piton	Tanggal 3.10.12
tekanan listrik	11.8
Lr	0,0001
Ukuran batch	16
Pekerja	4
Masa	100
Pengoptimal	Adam

2.3. Indikator Evaluasi

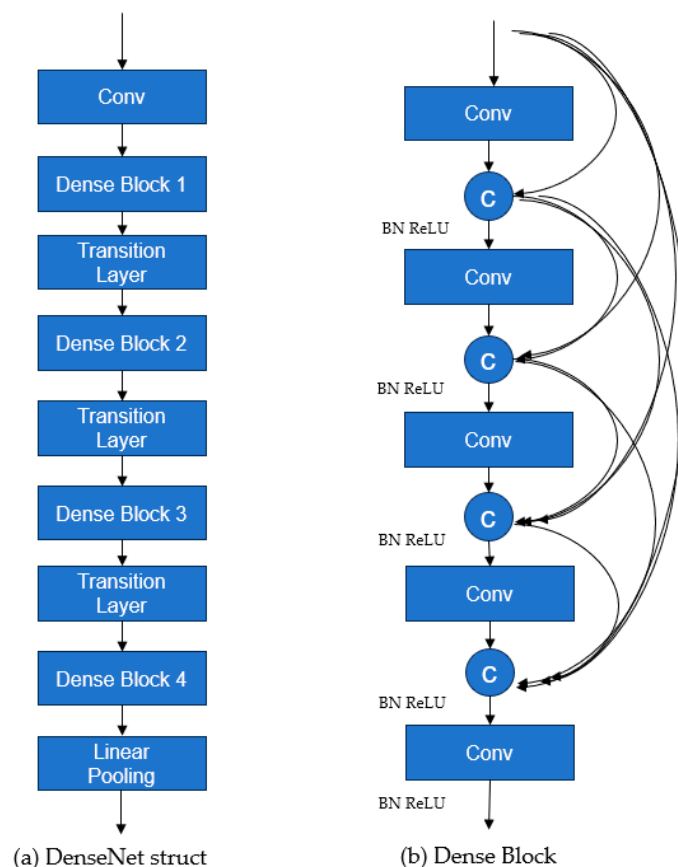
Kinerja deteksi dalam penelitian ini dievaluasi menggunakan presisi, akurasi, recall, jumlah parameter, dan skor F1 [32]. TP (True Positive) merujuk pada jumlah sampel yang diprediksi dengan benar sebagai positif oleh model, TN (True Negative) merujuk pada jumlah sampel yang diprediksi dengan benar sebagai negatif oleh model, FP (False Positive) merujuk pada jumlah sampel yang diprediksi secara salah sebagai positif oleh model, dan FN (False Negative) merujuk pada jumlah sampel yang diprediksi secara salah sebagai negatif oleh model. Presisi mengukur proporsi sampel positif aktual di antara sampel yang diprediksi sebagai positif oleh model. Akurasi adalah probabilitas sampel positif aktual di antara semua sampel yang diprediksi sebagai positif. Recall mengukur proporsi sampel positif aktual yang diprediksi dengan benar sebagai positif oleh model. Biasanya ada trade-off antara presisi dan recall. Meningkatkan presisi dapat mengurangi recall, dan sebaliknya. Untuk mengevaluasi kinerja model secara komprehensif, skor F1, yang merupakan rata-rata harmonik presisi dan recall, sering digunakan, seperti yang ditunjukkan dalam rumus berikut [33]:

$$\begin{aligned}
 \text{Ketepatan} &= \frac{TP}{TP + FP} \\
 \text{Presisi} &= \frac{TP}{TP + FN} \\
 \text{Mengingat} &= \frac{TP}{TP + FN} \\
 F1 &= 2 \times \frac{\text{Presisi} \times \text{Mengingat}}{\text{Presisi} + \text{Mengingat}}
 \end{aligned}$$

2.4. Jaringan DenseNet

Dalam jaringan saraf konvolusional yang dalam, masalah seperti gradien menghilang atau gradien meledak sering terjadi. ResNet mengusulkan metode koneksi lintas lapisan untuk mengatasi masalah ini. Namun, koneksi lintas lapisan ResNet diimplementasikan dengan penambahan, yang memungkinkan setiap lapisan untuk secara langsung mengakses hanya keluaran dari lapisan sebelumnya. Hal ini mengakibatkan ResNet menggunakan kembali lebih sedikit fitur yang efektif. Ide inti DenseNet adalah untuk meningkatkan transmisi fitur dan aliran gradien melalui koneksi padat, sehingga menggunakan kembali lebih banyak fitur yang efektif dan mencapai pelatihan jaringan yang efisien. Dalam DenseNet, setiap lapisan terhubung ke semua lapisan sebelumnya, yang berarti bahwa lapisan ke- i menerima peta fitur dari semua lapisan ke- $i-1$ lapisan sebelumnya sebagai input. Metode koneksi ini secara signifikan meningkatkan aliran informasi dan membantu mengatasi masalah gradien yang menghilang.

Struktur jaringan DenseNet terutama terdiri dari tiga bagian: DenseLayer, DenseBlock, dan Transisi, seperti yang ditunjukkan pada Gambar 2. Struktur DenseNet yang ditunjukkan pada Gambar 2a. DenseLayer hanyalah lapisan konvolusional yang digunakan untuk ekstraksi fitur dasar dalam jaringan. DenseBlock adalah bagian inti dari jaringan dan berfungsi sebagai unit dasar (Gambar 2b). Dalam modul ini, koneksi padat digunakan untuk memanfaatkan fitur berulang kali [34]. Modul Transition berisi lapisan konvolusional dan lapisan pooling. Lapisan ini digunakan untuk menghubungkan DenseBlock yang berbeda, memastikan bahwa lebar dan tinggi peta fitur tetap konsisten. Input ke modul Transition adalah matriks fitur berukuran $C_{\text{Bahasa Indonesia}} \times H_{\text{Bahasa Indonesia}} \times W_{\text{Bahasa Indonesia}}$. DenseBlock mengikuti modul Transisi memerlukan input berukuran $C1_{\text{Bahasa Indonesia}} \times H1_{\text{Bahasa Indonesia}} \times W1_{\text{Bahasa Indonesia}}$. Oleh karena itu, jumlah saluran dalam lapisan konvolusional dalam modul Transisi ditetapkan ke $C1$, dan ukuran lapisan pengumpulan adalah $2_{\text{Bahasa Indonesia}} \times 2_{\text{Bahasa Indonesia}} \times 2_{\text{Bahasa Indonesia}}$, memastikan bahwa persyaratan lebar dan tinggi untuk peta fitur input ke DenseBlock terpenuhi.

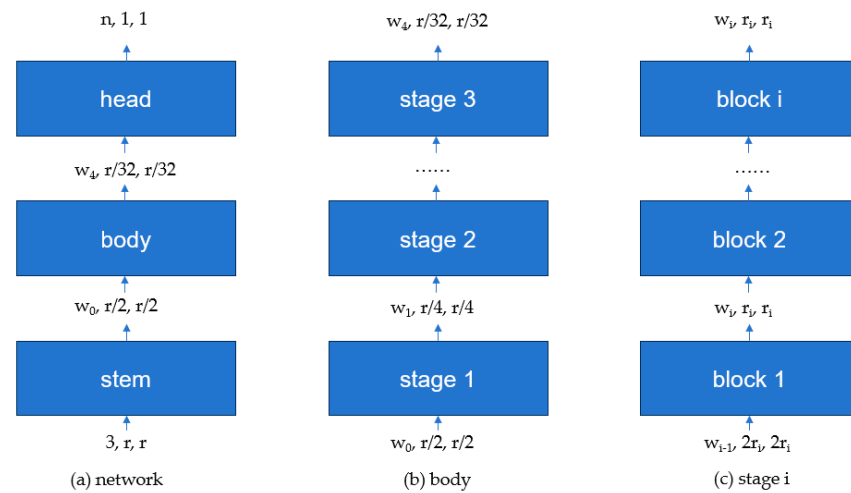


Gambar 2.Diagram struktur jaringan DenseNet.

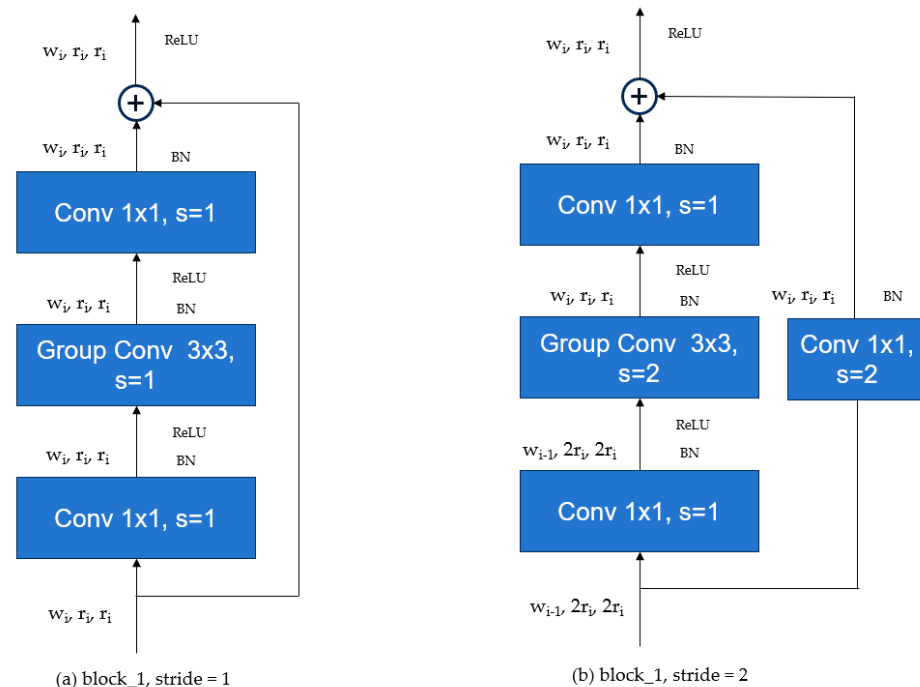
2.5. Jaringan Regulasi

RegNet (Regularization Network) adalah arsitektur jaringan saraf konvolusional (CNN) yang fleksibel dan terukur yang diusulkan oleh para peneliti di Facebook AI Research (FAIR) pada tahun 2020 [35]. Tujuan utama RegNet adalah untuk menciptakan serangkaian jaringan yang efisien dengan memperkenalkan prinsip dan batasan desain baru [35], yang membahas masalah kompleksitas dan biaya komputasi dalam pencarian arsitektur otomatis. RegNet mendefinisikan arsitektur jaringan dengan cara yang diparameterisasi, termasuk aspek-aspek seperti lebar jaringan, kedalaman, dan konfigurasi konvolusi grup, sehingga memungkinkan pembuatan jaringan dengan berbagai skala dan kompleksitas. RegNet menyediakan kerangka kerja fleksibel yang dapat menyesuaikan kompleksitas jaringan berdasarkan tugas-tugas tertentu dan persyaratan sumber daya komputasi.

Struktur jaringan RegNet ditunjukkan pada Gambar 3. Arsitektur RegNet terutama terdiri dari tiga bagian: batang (Gambar 3a), badan (Gambar 3b), dan kepala (Gambar 3c). Batangnya adalah lapisan konvolusional dengan 32 filter, masing-masing dengan ukuran kernel 3 dan langkah 2. Ini juga mencakup Normalisasi Batch dan fungsi aktivasi ReLU. Badan terdiri dari empat tahap yang ditumpuk, di mana tinggi dan lebar keluaran matriks fitur dari setiap tahap dibagi dua dibandingkan dengan masukan. Setiap tahap terdiri dari serangkaian blok, seperti yang ditunjukkan pada Gambar 4. Blok pertama di setiap tahap memiliki langkah 2, seperti yang digambarkan pada (Gambar 4b), sedangkan blok yang tersisa memiliki langkah 1, seperti yang digambarkan pada (Gambar 4a). Kepala adalah pengklasifikasi jaringan, yang terdiri dari lapisan pengumpulan rata-rata global dan lapisan yang terhubung sepenuhnya.



Gambar 3. Diagram struktur jaringan dari Jaringan Regularisasi.



Gambar 4. Diagram skema modul Jaringan Regularisasi.

3. Hasil


3.1. Studi Perbandingan

Algoritma klasifikasi arus utama yang dibandingkan dalam penelitian ini meliputi VGG16 [36], GoogleNet [37], ResNet34 [38], Jaringan Seluler v2 [39], Jaringan Seluler v3 [40], ShuffleNet v1 [41], ShuffleNet v2 [42], Jaringan Padat, Jaringan Efisien v2 [43], Transformator Swin [44], SelulerVIT [45], RegNet, dan Transformator Visi [46]. Hasil perbandingan algoritma ini tanpa bobot yang telah dilatih sebelumnya ditunjukkan pada Tabel 3. Model DenseNet memberikan kinerja terbaik, dengan presisi 95,7%, akurasi 95,3%, recall 94,8%, skor F1 95,0%, dan jumlah parameter 6,97 juta. Performa terbaik berikutnya adalah ShuffleNet v1, dengan presisi 94,2%, akurasi 93,6%, recall 92,9%, skor F1 93,2%, dan jumlah parameter hanya 0,92 juta, yang merupakan seperdelapan ukuran model DenseNet. Perubahan nilai kerugian model selama pelatihan dan kinerjanya pada set validasi ditunjukkan pada Gambar 5. Pada (Gambar 5a), variasi dalam fungsi kerugian pelatihan seiring dengan meningkatnya jumlah periode pelatihan diilustrasikan, di mana fungsi kerugian secara bertahap menurun dan stabil. Dalam (Gambar 5b), perubahan akurasi pada set validasi seiring dengan berjalannya pelatihan

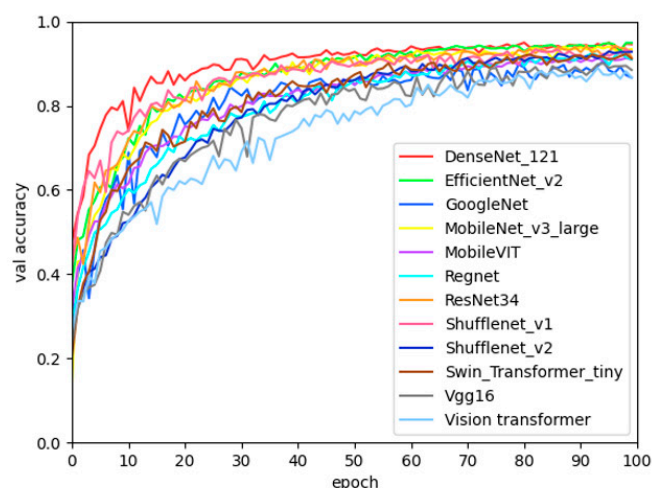
digambarkan, memperlihatkan bahwa akurasi meningkat seiring dengan jumlah periode pelatihan dan secara bertahap menjadi stabil.

Tabel 3. Eksperimen perbandingan.

Nama Model	Ketepatan%	Presisi%	Mengingat%	Skor F1	Parameter/M
Vgg16	92.1	90.5	90.1	90.3	134.31
Google Jaringan	90.3	88.7	88.8	88.7	10.34
ResNet34	94.0	93.0	92.7	92.8	Tanggal 21.29
Jaringan Seluler v2	93.0	92.3	90.6	91.3	2.24
MobileNet v3 kecil	91.9	90.3	89.8	90.0	1.53
MobileNet v3 besar	93.8	92.1	92.6	92.3	4.22
ShuffleNet v2	93.3	92.5	91.4	91.8	1.27
ShuffleNet v1	94.2	93.6	92.9	93.2	0.92
Jaringan Padat	95.7	95.3	94.8	95.0	6.97
Jaringan Efisien v2	95.3	94.2	93.6	93.9	tanggal 24.20
Transformator Swin kecil	92.8	91.2	90.3	90.7	27.53
PonselVIT	93.8	92.4	92.3	91.2	0,96
Jaringan Reg	93.8	91.8	92.0	91.8	3.91
Transformator Visi	91.8	90.5	90.8	90.6	85.81



(a) Train loss and epoch



(b) Val accuracy and epoch

Gambar 5. Grafik perubahan nilai fungsi kerugian dan akurasi validasi selama pelatihan.

Dalam algoritma klasifikasi gambar, jumlah parameter suatu model menentukan kompleksitas dan kebutuhan komputasinya. Model dengan jumlah parameter kurang dari 10 M cocok untuk perangkat dengan sumber daya yang sangat terbatas, seperti sistem tertanam, perangkat seluler, perangkat tepi, dan aplikasi seluler [47]. Penelitian ini mengkaji model dengan jumlah parameter kurang dari 10 M dalam identifikasi penyakit padi. Hasil akurasi model tersebut pada masing-masing kategori ditunjukkan pada Tabel 1.4. Di antara semuanya, akurasi tertinggi untuk identifikasi daun sehat adalah 97,4%, sedangkan akurasi terendah untuk identifikasi Tungro adalah 88,0%. Secara keseluruhan, model DenseNet menunjukkan kinerja terbaik di semua kategori.

Nilai F1 model dengan jumlah parameter kurang dari 10 M pada setiap kategori ditunjukkan pada Tabel 5. Skor F1 tertinggi adalah untuk kategori Dead Heart, dengan nilai F1 sebesar 99,5%, sedangkan skor F1 terendah adalah untuk kategori Tungro, dengan nilai F1 sebesar 90,7%. Di semua kategori, model DenseNet menunjukkan kinerja F1 keseluruhan terbaik.

Akurasi model dengan jumlah parameter lebih dari 10 M pada setiap kategori ditunjukkan pada Tabel 6. Akurasi tertinggi adalah untuk kategori Dead Heart, dengan akurasi 99,3%, sedangkan akurasi terendah adalah untuk kategori Tungro, dengan akurasi 88,0%. Di semua kategori, model dengan akurasi keseluruhan terbaik adalah EfficientNet v2.

Skor F1 model dengan jumlah parameter lebih dari 10 M di setiap kategori ditunjukkan pada Tabel 7. Skor F1 tertinggi adalah untuk kategori Dead Heart, dengan skor F1 sebesar 99,1%, sedangkan skor F1 terendah adalah untuk Tungro, dengan skor F1 sebesar 86,6%. Di semua kategori, model dengan kinerja F1 keseluruhan terbaik adalah EfficientNet v2.

Tabel 4. Keakuratan model dengan parameter volume kurang dari 10 M pada berbagai kategori penyakit.

Nama Penyakit	MobileNet v3 Besar	Shufflenet v1	Shufflenet v2	Jaringan Padat 121	PonselVIT	Jaringan Reg
Penyakit hawar daun bakteri	93.7	96.8	92.6	95.8	92.6	91.6
Garis daun bakteri	88.0	89.6	90.4	92.0	88.8	88.0
Penyakit hawar malai bakteri	98.5	97.0	97.0	97.0	98.5	97.0
Ledakan	94.8	92.5	94.2	96.8	95.1	96.8
Bercak coklat	92.7	93.8	94.3	94.8	95.8	91.2
Hati Mati	98.9	99.7	98.9	99.3	97.9	97.9
Penyakit bulai berbulu halus	90.3	88.7	83.9	92.7	86.3	91.9
Bahasa Spanyol	93.4	94.9	91.2	95.3	92.4	94.6
Normal	94.3	95.7	96.6	97.4	96.3	96.9
tungro	84.0	84.0	76.0	88.0	80.0	84.0
Jelaga	89.2	86.5	87.8	94.6	90.5	93.2
Penyakit busuk daun padi	93.5	95.4	93.5	94.0	93.5	88.9

Tabel 5. Skor F1 model dengan parameter volume kurang dari 10 M pada berbagai kategori penyakit.

Nama Penyakit	MobileNet v3 Besar	Shufflenet v1	Shufflenet v2	Jaringan Padat 121	PonselVIT	Jaringan Reg
Penyakit hawar daun bakteri	89.5	95.3	91.6	94.8	93.1	92.1
Garis daun bakteri	88.7	89.9	90.7	92.3	91.4	90.9
Penyakit hawar malai bakteri	97.1	94.9	92.8	98.5	95.0	95.6
Ledakan	95.2	94.1	94.2	96.1	95.0	95.6
Bercak coklat	93.9	94.0	94.5	95.0	93.0	94.4
Hati Mati	98.6	99.0 tahun	98.6	99.5	98.7	98.4
Penyakit bulai berbulu halus	87.8	86.9	88.2	92.0	87.7	86.0
Bahasa Spanyol	93.5	93.8	93.4	94.8	93.3	95.1
Normal	95.2	95.7	93.1	97.0	95.3	94.9
tungro	83.9	89.4	82.6	90.7	81.6	86.6
Jelaga	91.1	90.8	89.0	94.0	90.5	91.4
Penyakit busuk daun padi	93.3	94.5	92.9	95.7	93.5	92.1


Tabel 6. Keakuratan model dengan parameter volume lebih besar dari 10 M pada berbagai kategori penyakit.

Nama Penyakit	Vgg16	Google Jaringan	ResNet34	Jaringan Efisien v2	babi Transformator	Penglihatan Transformator
Penyakit hawar daun bakteri	82.1	82.1	91.6	92.6	84.2	89.5
Garis daun bakteri	87.2	86.4	88.0	92.8	88.8	90.4
Penyakit hawar malai bakteri	94.0	92.5	97.0	97.0	94.0	98.5
Ledakan	95.7	86.4	96.8	96.8	96.2	93.6
Bercak coklat	89.1	87.5	92.0	96.4	93.3	91.7
Hati Mati	99.0 tahun	98.3	97.9	99.3	98.6	95.1
Penyakit bulai berbulu halus	85.5	89.5	91.9	88.7	82.2	87.9
Bahasa Spanyol	94.0	90.2	94.6	94.3	91.2	89.9
Normal	96.0	94.3	96.9	96.5	94.9	93.7
tungro	86.0	82.0	84.0	84.0	84.0	88.0
Jelaga	86.5	85.1	93.2	87.8	79.7	81.1
Penyakit busuk daun padi	89.4	90.8	88.9	96.8	96.8	90.8

Tabel 7.Skor F1 model dengan parameter volume lebih besar dari 10 M pada berbagai kategori penyakit.

Nama Penyakit	Vgg16	Google Jaringan	ResNet34	Jaringan Efisien v2	babi Transformator	Penglihatan Transformator
Penyakit hawar daun bakteri	85.2	80.8	92.1	93.1	87.0	86.7
Garis daun bakteri	88.2	88.5	90.9	91.7	87.4	90.4
Penyakit hawar malai bakteri	94.7	91.8	95.6	97.7	95.4	97.8
Ledakan	93.0	90.7	95.6	96.0	94.5	93.3
Bercak coklat	90.5	87.3	94.4	96.1	93.5	92.2
Hati Mati	98.6	97.0	98.4	99.1	97.9	95.8
Penyakit bulai berbulu halus	82.8	83.5	86.0	88.7	84.7	84.5
Bahasa Spanyol	93.0	90.4	95.1	95.8	92.0	89.3
Normal	95.1	92.6	94.9	97.0	95.1	94.4
tungro	85.1	83.7	86.6	85.7	80.8	84.6
Jelaga	86.5	87.5	91.4	90.8	85.5	85.7
Penyakit busuk daun padi	90.6	90.1	92.1	94.4	94.8	92.7

Singkatnya, di antara model dengan jumlah parameter kurang dari 10 M, DenseNet memberikan kinerja terbaik, dengan presisi 95,7%, akurasi 95,3%, recall 94,8%, inti F1 95,0%, dan jumlah parameter hanya 6,97 M. Di antara model dengan jumlah parameter lebih dari 10 M, EfficientNet v2 memberikan kinerja terbaik, dengan presisi 95,3%, akurasi 94,2%, recall 93,6%, skor F1 93,9%, dan jumlah parameter 24,20 M. DenseNet tidak hanya memiliki presisi, akurasi, recall, dan skor F1 yang lebih tinggi daripada EfficientNet v2, tetapi jumlah parameternya juga seperdelapan dari EfficientNet v2, yang membuat DenseNet lebih cocok untuk implementasi algoritma praktis. Model DenseNet dievaluasi pada set validasi, dan matriks kebingungannya ditunjukkan pada Gambar 6. Dapat dilihat bahwa model tersebut memiliki akurasi yang tinggi dalam mengidentifikasi penyakit padi.

**Gambar 6.**Matriks kebingungan model DenseNet pada set pengujian.

3.2. Eksperimen Pembelajaran Transfer

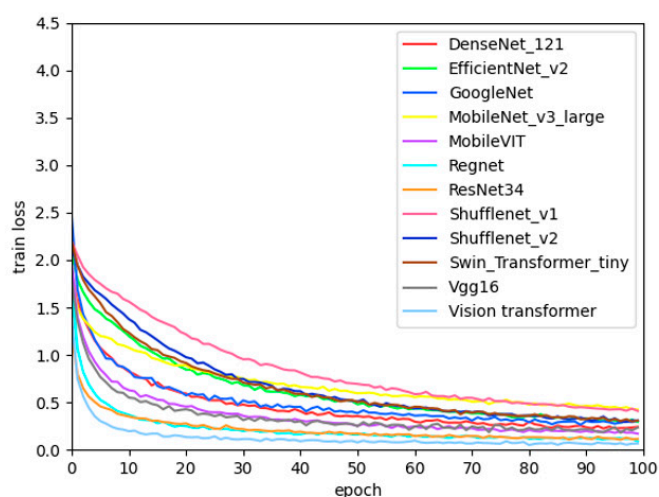
Pembelajaran transfer melibatkan penerapan model pembelajaran mendalam yang telah dilatih sebelumnya pada kumpulan data berskala besar ke kumpulan data tugas baru yang terkait. Pembelajaran transfer sangat efektif dalam visi komputer, terutama ketika data terbatas [48–50]. Dataset ImageNet adalah dataset skala besar untuk tugas pengenalan objek dan klasifikasi gambar, berisi lebih dari 14 juta gambar di ribuan kategori objek [51–53]. Oleh karena itu, penelitian ini

menggunakan model yang dilatih ImageNet untuk penelitian penyakit padi. Hasil percobaan ditunjukkan pada Tabel 8. Di antara model-model tersebut, RegNet memiliki performa terbaik, dengan akurasi 96,8%, presisi 96,2%, recall 95,9%, dan skor F1 96,0%, dengan jumlah parameter hanya 3,91 juta. Performa terbaik berikutnya adalah ResNet34, dengan akurasi 96,7%, presisi 96,0%, recall 95,7%, dan skor F1 95,8%. Namun, jumlah parameternya lebih tinggi, yaitu 21,29 juta, yang lebih dari lima kali lipat jumlah parameter RegNet.


Tabel 8. Eksperimen dengan beban yang telah dilatih sebelumnya.

Nama Model	Ketepatan%	Presisi%	Mengingat%	Skor F1	Parameter/M
Vgg16	93.5	93.4	92.8	93.1	134.31
Google Jaringan	91.0	89.0	90.0	89.2	10.34
ResNet34	96.7	96.0	95.7	95.8	Tanggal 21,29
Jaringan Seluler v2	71.6	73.4	71.0	71.7	2.24
MobileNet v3_kecil	87.6	87.9	86.0	86.8	1.53
MobileNet v3_besar	91.8	91.6	91.0	91.3	4.22
Shufflenet v2	96.6	95.7	95.7	95.7	1.27
Shufflenet v1	94.4	93.7	92.2	92.9	0.92
Jaringan Padat	94.9	94.5	93.8	94.2	6.97
Jaringan Efisien v2	95.6	94.2	94.3	94.2	tanggal 24,20
Transformator Swin kecil	94.0	93.2	92.6	92.9	27.53
PonselVIT	92.6	91.1	91.3	91.1	0,96
Jaringan Reg	96.8	96.2	95.9	96.0	3.91
Transformator Visi	96.6	96.2	95.9	96.0	85.81

Perubahan nilai kerugian model dan akurasi validasi selama pelatihan dengan bobot yang telah dilatih ditunjukkan pada Gambar 7; (Angka 7a) menggambarkan variasi fungsi kerugian pelatihan seiring dengan meningkatnya jumlah periode pelatihan, dimana dapat diamati bahwa fungsi kerugian secara bertahap menurun dan stabil, dan (Gambar 7b) menggambarkan perubahan dalam akurasi validasi seiring dengan peningkatan periode pelatihan, yang menunjukkan bahwa akurasi meningkat dan akhirnya stabil. Gambar tersebut menunjukkan bahwa memperkenalkan bobot yang telah dilatih sebelumnya memungkinkan model untuk konvergen lebih cepat.



(a) Train loss and epoch



(b) Val accuracy and epoch

Gambar 7. Grafik perubahan nilai fungsi kerugian dan akurasi validasi selama pelatihan.

Akurasi model dengan jumlah parameter kurang dari 10 M pada setiap kategori ditunjukkan pada Tabel 1.9. Akurasi tertinggi adalah untuk kategori Dead Heart, dengan akurasi 99,3%, sedangkan akurasi terendah adalah untuk Tungro, dengan akurasi 92,0%. Di semua kategori, model dengan akurasi keseluruhan terbaik adalah RegNet.

Tabel 9.Keakuratan model dengan parameter volume kurang dari 10 M pada berbagai kategori penyakit.

Nama Penyakit	MobileNet v3 Besar	ShuffleNet v1	ShuffleNet v2	Jaringan Padat	PonselVIT	Jaringan Reg
Penyakit hawar daun bakteri	92.6	94.7	94.7	97.9	93.6	93.7
Garis daun bakteri	92.0	94.4	96.0	92.8	89.6	96.8
Penyakit hawar malai bakteri	94.0	86.5	98.5	97.0	97.0	98.5
Ledakan	93.6	97.7	95.9	95.1	94.2	98.0
Bercak coklat	87.5	95.8	98.9	94.8	89.6	97.4
Hati Mati	97.2	98.2	99.3	98.9	98.2	99.3
Penyakit bulai berbulu halus	86.3	90.3	93.5	86.3	88.7	93.5
Bahasa Spanyol	89.0	94.0	95.6	93.4	92.4	96.2
Normal	94.6	96.0	97.4	98.0	93.2	98.0
tungro	86.0	82.0	88.0	86.0	86.0	92.0
Jelaga	89.2	86.5	93.2	91.9	81.1	91.9
Penyakit busuk daun padi	89.4	90.3	97.2	94.0	91.2	95.8

Skor F1 model dengan jumlah parameter kurang dari 10 M di setiap kategori ditunjukkan pada Tabel10Skor F1 tertinggi adalah untuk kategori Dead Heart, dengan skor F1 sebesar 99,5%, sedangkan skor F1 terendah adalah untuk Tungro, dengan skor F1 sebesar 90,2%. Di semua kategori, model dengan kinerja F1 keseluruhan terbaik adalah RegNet.

Tabel 10.Skor F1 model dengan parameter volume kurang dari 10 M pada berbagai kategori penyakit.

Nama Penyakit	MobileNet v3 Besar	ShuffleNet v1	ShuffleNet v2	Jaringan Padat	PonselVIT	Jaringan Reg
Penyakit hawar daun bakteri	89.7	94.2	94.7	96.9	91.3	94.7
Garis daun bakteri	91.6	92.9	96.0	93.9	87.8	95.6
Penyakit hawar malai bakteri	93.3	92.0	96.3	97.0	95.6	98.5
Ledakan	92.3	95.0	96.5	94.8	92.7	96.7
Bercak coklat	89.2	95.4	98.2	96.0	93.2	97.4
Hati Mati	97.4	97.8	99.3	99,0 tahun	98.3	99.5
Penyakit bulai berbulu halus	87.3	91.4	93.5	87.7	86.3	93.5
Bahasa Spanyol	88.3	94.4	96.0	94.7	93.0	96.3
Normal	93.8	95.4	96.8	95.5	94.1	97.7
tungro	88.6	84.5	89.8	87.7	81.1	90.2
Jelaga	91.7	88.3	93.8	93.1	88.2	95.1
Penyakit busuk daun padi	91.7	93.3	97.2	93.3	90.8	97.4

Akurasi model dengan jumlah parameter lebih dari 10 M pada setiap kategori ditunjukkan pada Tabel11Akurasi tertinggi adalah untuk kategori penyakit blas, dengan akurasi 100%, sedangkan akurasi terendah adalah untuk kategori penyakit bulai, dengan akurasi 93,5%. Di semua kategori, model dengan akurasi keseluruhan terbaik adalah Vision Transformer.

Tabel 11.Keakuratan model dengan parameter volume lebih besar dari 10 M pada berbagai kategori penyakit.


Nama Penyakit	Vgg16	Google Jaringan	ResNet34	Jaringan Efisien v2	babi Transformator	Penglihatan Transformator
Penyakit hawar daun bakteri	84.2	81.0	96.8	98.9	90.5	96.8
Garis daun bakteri	91.2	87.2	96.8	92.8	87.2	95.2
Penyakit hawar malai bakteri	100	97.0	100	97.0	97.0	100
Ledakan	94.5	91.6	98.5	96.2	97.7	98.8
Bercak coklat	94.3	91.7	95.3	94.3	95.8	96.4
Hati Mati	98.6	95.1	99.6	99.6	99.3	99.3
Penyakit bulai berbulu halus	86.3	86.3	93.5	91.1	87.1	90.3
Bahasa Spanyol	91.8	93.4	94.6	94.6	94.0	94.6
Normal	97.7	92.0	97.7	97.1	93.4	97.7
tungro	94.0	88.0	86.0	80.0	88	90.0
Jelaga	95.6	82.4	91.9	93.2	90.5	95.9
Penyakit busuk daun padi	86.6	88.9	97.2	95.8	90.3	95.8

Skor F1 model dengan jumlah parameter lebih dari 10 M di setiap kategori ditunjukkan pada Tabel 12. Skor F1 tertinggi adalah untuk kategori Dead Heart, dengan skor F1 sebesar 99,5%, sedangkan skor F1 terendah adalah untuk kategori downy mildew, dengan skor F1 sebesar 93,5%. Di semua kategori, model dengan kinerja F1 keseluruhan terbaik adalah Vision Transformer.

Tabel 12. Skor F1 model dengan parameter volume lebih besar dari 10 M pada berbagai kategori penyakit.

Nama Penyakit	Vgg16	Google Jaringan	ResNet34	Jaringan Efisien v2	babi Transformator	Penglihatan Transformator
Penyakit hawar daun bakteri	86.9	86.1	94.7	93.9	92.4	95.8
Garis daun bakteri	93.4	86.5	95.6	93.1	88.9	96.3
Penyakit hawar malai bakteri	97.1	91.5	98.5	94.9	97.0	97.8
Ledakan	92.7	91.7	96.7	96.3	95.0	97.0
Bercak coklat	92.6	90.2	97.4	95.8	95.1	97.4
Hati Mati	98.9	96.6	99.5	99.7	99.3	99.3
Penyakit bulai berbulu halus	87.7	82.3	93.5	90.4	90.0	92.1
Bahasa Spanyol	92.8	92.1	96.3	95.3	92.6	95.1
Normal	95.5	94.0	97.7	97.2	94.3	97.0
tungro	94.0	84.6	90.2	83.3	84.6	91.8
Jelaga	95.2	85.3	95.1	95.1	92.4	94.6
Penyakit busuk daun padi	89.5	88.9	97.4	95.2	92.6	97.6

Singkatnya, di antara model dengan jumlah parameter kurang dari 10 M, RegNet memberikan performa terbaik, dengan akurasi 96,8%, presisi 96,2%, recall 95,9%, dan skor F1 96,0%, dengan jumlah parameter hanya 3,91 M. Di antara model dengan jumlah parameter lebih dari 10 M, Vision Transformer adalah yang berkinerja terbaik, dengan akurasi 96,6%, presisi 96,2%, recall 95,9%, dan skor F1 96,0%, dengan jumlah parameter 85,81 M. RegNet tidak hanya melampaui Vision Transformer dalam akurasi, presisi, recall, dan skor F1, tetapi juga memiliki jumlah parameter yang seperduapuluh dari Vision Transformer, yang membuat RegNet lebih cocok untuk implementasi algoritma praktis. Model RegNet dievaluasi pada set validasi, dan matriks kebingungannya ditunjukkan pada Gambar 8. Dibandingkan dengan matriks kebingungan model DenseNet pada Gambar 6, RegNet menunjukkan kinerja yang lebih baik.



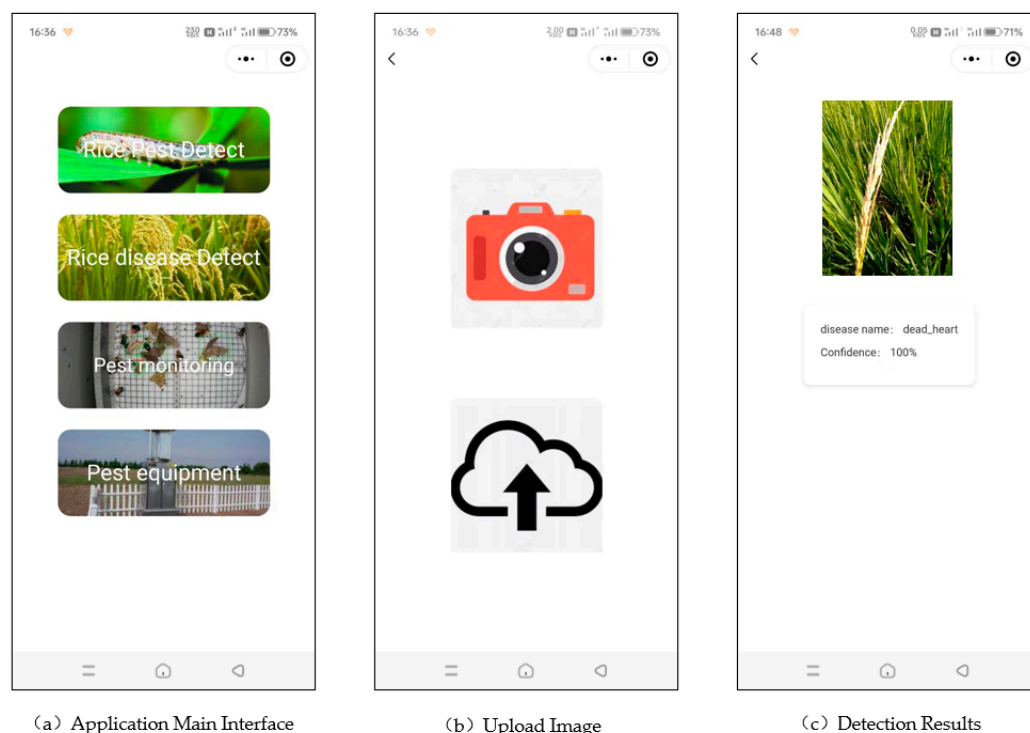
Gambar 8. Matriks kebingungan model RegNet pada set pengujian.

Dengan menggabungkan bobot yang telah dilatih sebelumnya, sebagian besar model telah menunjukkan peningkatan dalam akurasi, presisi, ingatan, dan skor F1. Akurasi pengenalan model RegNet meningkat sebesar 3,0%, presisi sebesar 4,4%, ingatan sebesar 3,9%, dan skor F1 sebesar 4,2%, yang menyoroti pentingnya pembelajaran transfer. Tanpa pembelajaran transfer, model dengan kinerja keseluruhan terbaik adalah DenseNet, dengan akurasi 95,7%, presisi 95,3%, ingatan 94,8%, dan skor F1 95,0%, dengan jumlah parameter hanya 6,97 M. Membandingkan RegNet dengan bobot yang telah dilatih sebelumnya dengan DenseNet, akurasi pengenalan RegNet meningkat sebesar 1,1%, presisi sebesar 0,9%, ingatan sebesar 1,1%, dan skor F1 sebesar 1,0%, sementara ukuran model RegNet hanya setengah dari DenseNet. Secara keseluruhan, DenseNet dengan pembelajaran transfer berkinerja terbaik, dengan ukuran model yang lebih kecil, membuatnya cocok untuk implementasi algoritma praktis.

3.3. Aplikasi Pendeteksi Penyakit Padi

Penelitian ini mengembangkan aplikasi identifikasi penyakit padi berdasarkan model RegNet dengan bobot yang telah dilatih sebelumnya, cocok untuk pekerja pertanian yang membawa perangkat seluler di ladang. Waktu inferensi rata-rata aplikasi berada dalam kisaran 200 ms, memenuhi persyaratan kerja harian pengguna. Aplikasi deteksi penyakit padi dikembangkan menggunakan teknologi Uni-app [54], kerangka kerja lintas platform yang mendukung penulisan sekali dan berjalan di berbagai platform, termasuk program mini, H5, dan aplikasi. Portabilitasnya yang tinggi membuatnya sangat cocok untuk pengembangan aplikasi seluler. Penyebaran model ditangani menggunakan Python dan kerangka kerja web berbasis Python FastAPI, dengan Python yang ideal untuk pengembangan cepat, analisis data, dan pembelajaran mesin, sementara FastAPI difokuskan pada pembangunan API web berkinerja tinggi [55].

Aplikasi identifikasi penyakit padi ditunjukkan pada Gambar 9, dengan antarmuka intuitif yang memudahkan pengguna mengidentifikasi penyakit padi. Panel (a) menampilkan beranda aplikasi, yang memiliki empat opsi: identifikasi hama padi, identifikasi penyakit padi, pemantauan hama, dan peralatan pemantauan hama. Setelah memilih fungsi identifikasi penyakit padi, tersedia dua opsi: mengambil dan mengunggah gambar menggunakan kamera atau mengunggah gambar dari galeri lokal, seperti yang ditunjukkan pada panel (b). Setelah mengunggah gambar, seperti yang ditunjukkan pada panel (c), aplikasi akan menampilkan gambar yang diunggah, nama penyakit padi yang terdeteksi dalam gambar, dan tingkat kepercayaan model terhadap identifikasinya.



Gambar 9. Diagram skema antarmuka aplikasi identifikasi penyakit padi.

4. Diskusi

Dalam studi ini, skor F1 dan akurasi untuk setiap kelas bervariasi, dan kami melakukan analisis untuk memahami alasan di balik hal ini. Pertama, jumlah sampel untuk setiap kelas penyakit berbeda, yang menyebabkan variabilitas dalam efektivitas pelatihan di seluruh kelas. Selain itu, informasi yang terkandung dalam gambar setiap kelas bervariasi. Setiap gambar penyakit menyertakan gejala dari berbagai tahap pertumbuhan, dan variasi signifikan dalam gejala ini dapat membuat pelatihan lebih menantang bagi model, seperti yang terlihat pada kelas seperti Tungro dan penyakit bulai.

Studi ini berfokus pada pengenalan penyakit padi multikelas dengan membandingkan kinerja algoritma deteksi paling canggih pada kumpulan data penyakit padi dan mengoptimalkan model dengan pembelajaran transfer untuk mengidentifikasi model deteksi terbaik untuk aplikasi. Namun, masih ada batasan tertentu. Pertama, karena metode deteksi yang lebih canggih muncul di masa mendatang, metode yang disajikan dalam studi ini mungkin memerlukan validasi lebih lanjut melalui eksperimen tambahan untuk mengonfirmasi keoptimalannya. Selain itu, pendekatan ideal untuk deteksi penyakit padi adalah otomatisasi penuh. Aplikasi yang dikembangkan dalam studi ini memerlukan deteksi penyakit manual untuk identifikasi. Pendekatan ini mungkin tidak mendeteksi tahap awal penyakit padi. Penelitian mendatang akan berkonsentrasi pada pengembangan sistem yang lebih otomatis untuk memantau pertumbuhan padi, yang merupakan arah penting untuk penelitian kami yang sedang berlangsung.

5. Kesimpulan

Diagnosis penyakit padi yang cepat dan akurat dapat mencegah penyebaran dalam skala besar dan penggunaan pestisida yang berlebihan, sehingga memastikan hasil panen dan kualitas padi. Saat ini, penelitian yang ada hanya membahas sejumlah penyakit padi yang terbatas, sehingga kurang sesuai untuk berbagai penyakit padi yang ada saat ini. Selain itu, penelitian saat ini kurang membahas algoritma deteksi tingkat lanjut, sehingga sulit untuk menentukan pendekatan aplikasi yang optimal. Untuk mengatasi masalah ini, penelitian ini menyusun kumpulan data penyakit padi multikelas yang mencakup 11 kategori penyakit dan kelas daun sehat, sehingga memberikan representasi kategori penyakit padi yang lebih komprehensif dan praktis. Lebih jauh lagi, studi ini mengevaluasi jaringan deteksi mutakhir, menemukan bahwa DenseNet menawarkan kinerja keseluruhan terbaik dengan akurasi 95,7%, presisi 95,3%, recall 94,8%, dan skor F1 95,0%, dengan jumlah parameter hanya 6,97 M. Menanggapi tren pembelajaran transfer saat ini, studi ini menggabungkan bobot yang telah dilatih sebelumnya dari dataset ImageNet skala besar dan menemukan bahwa model RegNet memberikan kinerja keseluruhan terbaik dengan akurasi 96,8%, presisi 96,2%, recall 95,9%, dan skor F1 96,0%, dengan jumlah parameter hanya 3,91 M. Selain itu, aplikasi untuk pengenalan penyakit padi berdasarkan model RegNet telah dikembangkan, menawarkan alat yang mudah digunakan dan efisien untuk mendiagnosis penyakit padi.

Kontribusi Penulis:Konseptualisasi, YL, LY dan YH; metodologi, YL; perangkat lunak, LY dan YH; validasi, LY dan YH; analisis formal, YL dan XC; investigasi, YL, XC, LY dan YH; sumber daya, XC; kurasi data, YL, LY dan YH; penulisan—persiapan draf asli, YL; penulisan—peninjauan dan penyuntingan, YL dan XC; visualisasi, YL, LY dan YH; supervisi, XC; administrasi proyek, XC; perolehan pendanaan, XC Semua penulis telah membaca dan menyetujui versi naskah yang diterbitkan.

Pendanaan:Penelitian tentang Peralatan Teknis Utama untuk Identifikasi dan Pengendalian Hama dan Penyakit Padi Berbasis AI. Proyek Kerja Sama Inovasi Regional Departemen Sains dan Teknologi Provinsi Sichuan, nomor hibah 24QYCX0185. Durasinya dari Januari 2024 hingga Desember 2025. Penelitian ini juga didukung oleh Proyek Demonstrasi Inovasi Transformasi Rantai Industri Penuh Industri Pakan dan Peningkatan Integrasi Industri-Pendidikan.

Pernyataan Ketersediaan Data:Kontribusi asli yang disajikan dalam penelitian disertakan dalam artikel; pertanyaan lebih lanjut dapat ditujukan kepada penulis terkait.

Ucapan Terima Kasih:Terima kasih kepada Konferensi tentang Visi Komputer dan Pengenalan Pola.

Konflik Kepentingan:Penulis menyatakan tidak ada konflik kepentingan.

Referensi

1. Li, R.; Chen, S.; Matsumoto, H.; Gouda, M.; Gafforov, Y.; Wang, M.; Liu, Y. Memprediksi penyakit padi menggunakan teknologi canggih pada skala berbeda: Status saat ini dan prospek masa depan.*aBIOTEK**Tahun 2023***Bahasa Indonesia: 4, hal. 359–371. [[Referensi silang](#) Bahasa Indonesia]
2. Worakuldumrongdej, P.; Maneewam, T.; Ruangwiset, A. Drone Penyemai Benih Padi untuk Pertanian. Dalam Prosiding Konferensi Internasional ke-19 tentang Kontrol, Otomasi, dan Sistem (ICCAS) 2019, Jeju, Republik Korea, 15–18 Oktober 2019. [[Referensi silang](#) Bahasa Indonesia]
3. Marzuki, OF; Teo, EYL; Rafie, ASM Mekanisme teknologi penyemaian drone: Suatu tinjauan.*Melayu. Untuk**Tahun 2021***Bahasa Indonesia: 84, 349–358.
4. Ahmed, K.; Shahidi, TR; Alam, SMI; Momen, S. Deteksi Penyakit Daun Padi Menggunakan Teknik Pembelajaran Mesin. Dalam Prosiding Konferensi Internasional 2019 tentang Teknologi Berkelanjutan untuk Industri 4.0 (STI), Dhaka, Bangladesh, 24–25 Desember 2019. [[Referensi silang](#) Bahasa Indonesia]
5. Pothen, ME; Pai, ML Deteksi Penyakit Daun Padi Menggunakan Pemrosesan Citra. Dalam Prosiding Konferensi Internasional Keempat tentang Metodologi Komputasi dan Komunikasi (ICCMC) 2020, Erode, India, 11–13 Maret 2020. [[Referensi silang](#) Bahasa Indonesia]
6. Jhatial, MJ; Syekh, RA; Syekh, NA; Rajper, S.; Arain, RH; Chandio, GH; Bhangwar, AQ; Syekh, H.; Syaikh, KH Deteksi penyakit daun padi berbasis deep learning menggunakan Yolov5.*Sukkur IBAJ. Matematika Komputasi. Sains**Tahun 2022***Bahasa Indonesia: 6, 49–61.
7. Liang, W.-J.; Zhang, H.; Zhang, G.-F.; Cao, H.-X. Pengenalan Penyakit Blas pada Tanaman Padi Menggunakan Jaringan Syaraf Tiruan Konvolusional Dalam. *Ilmu Pengetahuan**Tahun 2019***Bahasa Indonesia: 9, 2869. [[Referensi silang](#) Bahasa Indonesia] [Bahasa Indonesia: PubMed](#) Bahasa Indonesia]
8. Jiang, F.; Lu, Y.; Chen, Y.; Cai, D.; Li, G. Pengenalan gambar empat penyakit daun padi berdasarkan pembelajaran mendalam dan mesin vektor pendukung.*Komputasi. Elektron. Pertanian**Tahun 2020***Bahasa Indonesia: 179, 105824. [[Referensi silang](#) Bahasa Indonesia]
9. Shah, SR; Qadri, S.; Bibi, H.; Shah, SMW; Sharif, MI; Marinello, F. Membandingkan Inception V3, VGG 16, VGG 19, CNN, dan ResNet 50: Studi Kasus tentang Deteksi Dini Penyakit Padi.*Agronomi**Tahun 2023***Bahasa Indonesia: 13, tahun 1633. [[Referensi silang](#) Bahasa Indonesia]
10. Mannepalil, PK; Pathre, A.; Chhabra, G.; Ujjainkar, PA; Wanjari, S. Diagnosis penyakit hawar daun bakteri, penyakit busuk daun, dan bercak coklat pada daun padi menggunakan VGG16.*Procedia Ilmu Komputer**Tahun 2024***Bahasa Indonesia: 235, 193–200. [[Referensi silang](#) Bahasa Indonesia]
11. Mohapatra, S.; Marandi, C.; Sahoo, A.; Mohanty, S.; Tudu, K. Deteksi dan Klasifikasi Penyakit Daun Padi Menggunakan Jaringan Syaraf Tiruan Dalam. *Konferensi Internasional tentang Komputasi, Komunikasi dan Pembelajaran*; Springer: Cham, Swiss, 2022. [[Referensi silang](#) Bahasa Indonesia]
12. Poorni, R.; Kalaiselvan, P.; Thomas, N.; Srinivasan, T. Deteksi Penyakit Daun Padi menggunakan Jaringan Syaraf Tiruan Konvolusional. *Trans. ECS**Tahun 2022***Bahasa Indonesia: 107, 5069–5080. [[Referensi silang](#) Bahasa Indonesia]
13. Wang, Y.; Wang, H.; Peng, Z. Deteksi dan Klasifikasi Penyakit Padi Menggunakan Jaringan Syaraf Berbasis Perhatian dan Optimasi Bayesien.*Aplikasi Sistem Pakar**Tahun 2022***Bahasa Indonesia: 178, 114770. [[Referensi silang](#) Bahasa Indonesia]
14. Thai-Nghe, N.; Tri, NT; Hoa, NH Pembelajaran Mendalam untuk Mendeteksi Penyakit Daun Padi dalam Pertanian Cerdas. Dalam *Konferensi Internasional tentang Kecerdasan Buatan dan Big Data di Era Digital*; Springer: Cham, Swiss, 2022. [[Referensi silang](#) Bahasa Indonesia]
15. Lu, Y.; Yi, S.; Zeng, N.; Liu, Y.; Zhang, Y. Identifikasi penyakit padi menggunakan jaringan saraf konvolusional dalam. *Komputasi saraf**Tahun 2017***Bahasa Indonesia: 267, hal. 378–384. [[Referensi silang](#) Bahasa Indonesia]
16. Rahman, CR; Arko, PS; Ali, ME; Khan, MAI; Apon, SH; Nowrin, F.; Wasif, A. Identifikasi dan pengenalan penyakit dan hama padi menggunakan jaringan saraf konvolusional. *Biosistem. Ind**Tahun 2020***Bahasa Indonesia: 194, 112–120. [[Referensi silang](#) Bahasa Indonesia]
17. Sanya, DRA; Syed-Ab-Rahman, SF; Jia, A.; Padasayasime, D.; Kim, K.-M.; Ahohuendo, BC; Rohr, JR Tinjauan pendekatan untuk mengendalikan penyakit hawar daun bakteri pada tanaman padi. *Jurnal Dunia Mikrobiologi. Bioteknologi**Tahun 2022***Bahasa Indonesia: 38, 113. [[Referensi silang](#) Bahasa Indonesia] [Bahasa Indonesia: PubMed](#) Bahasa Indonesia]
18. Niño-Liu, DO; Ronald, PC; Bogdanove, AJ Xanthomonas oryzae pathovars: Patogen model tanaman model. *Mol. Patol Tanaman**Tahun 2010***Bahasa Indonesia: 7, hal. 303–324. [[Referensi silang](#) Bahasa Indonesia]
19. Wang, Z.; Chen, B.; Zhang, T.; Zhou, G.; Yang, X. Penyakit Mosaik Bergaris pada Padi: Karakteristik dan Strategi Pengendalian. *Depan. Mikrobiol**Tahun 2021***Bahasa Indonesia: 12, 715223. [[Referensi silang](#) Bahasa Indonesia]
20. Zhu, X.; Chen, L.; Zhang, Z.; Li, J.; Zhang, H.; Li, Z.; Pan, Y.; Wang, X. Diseksi berbasis genetik ketahanan terhadap penyakit bercak daun bakteri pada padi dengan GWAS. *BMC Plant Biol**Tahun 2023***Bahasa Indonesia: 23, 396. [[Referensi silang](#) Bahasa Indonesia]
21. Ngaliat, MS; Hata, EM; Zulperi, D.; Ismail, SI; Ismail, MR; Zainudin, NAIM; Saidi, NB; Yusof, MT Strategi terpuji untuk mengelola penyakit hawar malai bakteri pada tanaman padi menggunakan agen pengendalian hayati. *J. Mikrobiol Dasar**Tahun 2023***Bahasa Indonesia: 63, 1180–1195. [[Referensi silang](#) Bahasa Indonesia]
22. Shew, AM; Durand-Morat, A.; Nalley, LL; Zhou, X.-G.; Rojas, C.; Thoma, G. Pemanasan meningkatkan kejadian Penyakit Malai Bakteri (Burkholderia glumae) dan dampaknya terhadap produksi padi di Amerika Serikat. *PLOS SATU**Tahun 2019***Bahasa Indonesia: 14 Bahasa Indonesia: e0219199. [[Referensi silang](#) Bahasa Indonesia]
23. Wen, XH; Xie, MJ; Jiang, J.; Yang, B.; Shao, YL; He, W.; Liu, L.; Zhao, Y. Kemajuan dalam penelitian metode pengendalian penyakit ledakan padi. *Cina. Pertanian. Sains. Banteng**Tahun 2013***Bahasa Indonesia: 29, 190–195.
24. Sunder, S.; Singh, RAM; Agarwal, R. Bercak coklat pada beras: Tinjauan umum. *Fitopatol India**Tahun 2014***Bahasa Indonesia: 67, hal. 201–215.
25. Valent, B. Dampak Penyakit Blast: Dulu, Sekarang, dan Masa Depan. Dalam *Pohon Magnaporthe oryzae*; Metode dalam Biologi Molekuler; Humana: New York, NY, AS, 2021; hlm. 1–18. [[Referensi silang](#) Bahasa Indonesia]
26. Rubia, E.; Heong, K.; Zalucki, M.; Gonzales, B.; Norton, G. Mekanisme kompensasi tanaman padi terhadap kerusakan penggerek batang kuning Scirpophaga incertulas (Walker). *Tanaman Prot**tahun 1996***Bahasa Indonesia: 15, 335–340. [[Referensi silang](#) Bahasa Indonesia]
27. Azzam, O.; Rektor, TCB Biologi, Epidemiologi, dan Manajemen Penyakit Tungro Padi di Asia. *Tanaman Dis**tahun 2002***Bahasa Indonesia: 86, 88–100. [[Referensi silang](#) Bahasa Indonesia] [Bahasa Indonesia: PubMed](#) Bahasa Indonesia]

28. Hibino, H.; Cabunagan, RC Cabunagan. Virus terkait tungro pada padi dan hubungannya dengan tanaman inang dan vektor wereng. *Pertanian Tropis. Res. Ser.***tahun 1986**Bahasa Indonesia: 19, 173–182.
29. Khanal, S.; Gaire, SP; Zhou, X.-G. Kernel Smut dan False Smut: Penyakit padi yang sudah lama muncul—Sebuah tinjauan.*Fitopatologi Tahun 2023*Bahasa Indonesia: 113, 931–944. [[Referensi silang](#) Bahasa Indonesia]
30. Savary, S.; Willocquet, L.; Elazegui, FA; Teng, PS; Van Du, P.; Zhu, D.; Tang, Q.; Huang, S.; Lin, X.; Singh, HM; dkk. Kendala Hama Padi di Asia Tropis: Karakterisasi Profil Kerusakan Terkait Situasi Produksi.*Postep. Astron. Krakow***tahun 2000**Bahasa Indonesia: 84, hal. 341–356. [[Referensi silang](#) Bahasa Indonesia]Bahasa Indonesia: PubMed[Bahasa Indonesia]
31. Lee, FN Penyakit Hawar Selubung Padi: Penyakit Utama Padi. *Tanaman Dis.***tahun 1983**Bahasa Indonesia: 67, 829. [[Referensi silang](#) Bahasa Indonesia]
32. Bengio, Y.; Goodfellow, I.; Courville, A. *Pembelajaran Mendalam*; MIT Press: Cambridge, MA, AS, 2017; Volume 1.
33. Chen, L.; Li, S.; Bai, Q.; Yang, J.; Jiang, S.; Miao, Y. Tinjauan algoritma klasifikasi gambar berdasarkan jaringan saraf konvolusional. *Sensasi Jarak Jauh.***Tahun 2021**Bahasa Indonesia: 13, 4712. [[Referensi silang](#) Bahasa Indonesia]
34. Simonyan, K.; Zisserman, A. Jaringan Konvolusional Sangat Dalam untuk Pengenalan Gambar Skala Besar. *Bahasa Inggris arXiv***Tahun 2014**Bahasa Indonesia: arXiv:1409.1556v6. [[Referensi silang](#) Bahasa Indonesia]
35. Szegedy, C.; Liu, W.; Jia, Y.; Sermanet, P.; Reed, S.; Anguelov, D.; Erhan, D.; Vanhoucke, V.; Rabinovich, A.; Liu, W.; dkk. Mendalami Konvolusi. Dalam Prosiding Konferensi IEEE 2015 tentang Computer Vision and Pattern Recognition (CVPR), Boston, MA, AS, 7–12 Juni 2015; hlm. 1–9. [[Referensi silang](#) Bahasa Indonesia]
36. He, K.; Zhang, X.; Ren, S.; Sun, J. Pembelajaran residual mendalam untuk pengenalan gambar. Dalam Prosiding Konferensi IEEE tentang Computer Vision dan Pengenalan Pola, Las Vegas, NV, AS, 26 Juni–1 Juli 2016; hlm. 770–778.
37. Sandler, M.; Howard, A.; Zhu, M.; Zhmoginov, A.; Chen, L. MobileNetV2: Residual Terbalik dan Hambatan Linear. Dalam Prosiding Konferensi IEEE tentang Computer Vision dan Pengenalan Pola, Salt Lake City, UT, AS, 18–23 Juni 2018. [[Referensi silang](#) Bahasa Indonesia]
38. Howard, A.; Sandler, M.; Chen, B.; Wang, W.; Chen, L.-C.; Tan, M.; Chu, G.; Vasudevan, V.; Zhu, Y.; Pang, R.; dkk. Mencari MobileNetV3. Dalam Prosiding Konferensi Internasional IEEE/CVF tentang Visi Komputer (ICCV) 2019, Seoul, Republik Korea, 27 Oktober–2 November 2019; hlm. 1314–1324. [[Referensi silang](#) Bahasa Indonesia]
39. Zhang, X.; Zhou, X.; Lin, M.; Sun, J. ShuffleNet: Jaringan Syaraf Tiruan Konvolusional yang Sangat Efisien untuk Perangkat Seluler. Dalam Prosiding Konferensi IEEE tentang Visi Komputer dan Pengenalan Pola, Honolulu, HI, AS, 21–26 Juli 2017. [[Referensi silang](#) Bahasa Indonesia]
40. Ma, N.; Zhang, X.; Zheng, H.-T.; Sun, J. ShuffleNet V2: Panduan Praktis untuk Desain Arsitektur CNN yang Efisien. Dalam Prosiding Konferensi Eropa tentang Visi Komputer (ECCV), Munich, Jerman, 8–14 September 2018; Springer: Cham, Swiss, 2018; hlm. 116–131. [[Referensi silang](#) Bahasa Indonesia]
41. Huang, G.; Liu, Z.; Van Der Maaten, L.; Weinberger, KQ Jaringan Konvolusional yang Terhubung Padat. Dalam Prosiding Konferensi IEEE 2017 tentang Visi Komputer dan Pengenalan Pola, Honolulu, HI, AS, 21–26 Juli 2017; hlm. 2261–2269. [[Referensi silang](#) Bahasa Indonesia]
42. Tan, M.; Le, Q. EfficientNetV2: Model Lebih Kecil dan Pelatihan Lebih Cepat. *Bahasa Inggris arXiv***Tahun 2021**Jurnal Manajemen dan Kewirausahaan, arXiv:2104.00298.
43. Liu, Z.; Lin, Y.; Cao, Y.; Hu, H.; Wei, Y.; Zhang, Z.; Lin, S.; Guo, B. Swin Transformer: Hierarchical Vision Transformer menggunakan Shifted Windows. Dalam Prosiding Konferensi Internasional IEEE/CVF tentang Computer Vision, Montreal, BC, Kanada, 11–17 Oktober 2021. [[Referensi silang](#) Bahasa Indonesia]
44. Mehta, S.; Rastegari, M. MobileViT: Transformator Penglihatan yang Ringan, Serbaguna, dan Ramah Seluler. *Bahasa Inggris arXiv***Tahun 2021**Bahasa Indonesia: arXiv:2110.02178. [[Referensi silang](#) Bahasa Indonesia]
45. Radosavovic, I.; Kosaraju, RP; Girshick, R.; He, K.; Dollar, P. Mendesain Ruang Desain Jaringan. Dalam Prosiding Konferensi IEEE/CVF 2020 tentang Computer Vision and Pattern Recognition (CVPR), Seattle, WA, AS, 13–19 Juni 2020. [[Referensi silang](#) Bahasa Indonesia]
46. Dosovitskiy, A.; Beyer, L.; Kolesnikov, A.; Weissenborn, D.; Zhai, X.; Unterthiner, T.; Dehghani, M.; Minderer, M.; Heigold, G.; Gelly, S.; dkk. Sebuah Gambar Bernilai 16 *Bahasa Indonesia*: 16 Kata: Transformer untuk Pengenalan Gambar dalam Skala Besar. Dalam Prosiding Konferensi Internasional tentang Representasi Pembelajaran, Acara Virtual, Austria, 3–7 Mei 2021.
47. Menghani, G. Pembelajaran Mendalam yang Efisien: Survei tentang Membuat Model Pembelajaran Mendalam Lebih Kecil, Lebih Cepat, dan Lebih Baik. *ACM Komputasi.***Tahun 2023** Bahasa Indonesia: 55, 259.1–259.37.
48. Pan, SJ; Yang, Q. Survei tentang Pembelajaran Transfer. *IEEE Trans. Pengetahuan. Teknik Data.***Tahun 2010**Bahasa Indonesia: 22, 1345–1359. [[Referensi silang](#) Bahasa Indonesia]
49. Tan, C.; Sun, F.; Kong, T.; Zhang, W.; Yang, C.; Liu, C. Survei tentang Pembelajaran Transfer Mendalam. Dalam Prosiding Konferensi Internasional ke-27 tentang Jaringan Syaraf Tiruan, Rhodes, Yunani, 4–7 Oktober 2018; hlm. 270–279. [[Referensi silang](#) Bahasa Indonesia]
50. Zhuang, F.; Qi, Z.; Duan, K.; Xi, D.; Zhu, Y.; Zhu, H.; Xiong, H.; He, Q. Survei Komprehensif tentang Pembelajaran Transfer. *Proses IEEE Tahun 2021*Bahasa Indonesia: 109, 43–76. [[Referensi silang](#) Bahasa Indonesia]
51. Deng, J.; Dong, W.; Socher, R.; Li, L.-J.; Li, K.; Fei-Fei, L. ImageNet: Basis data gambar hierarkis berskala besar. Dalam Prosiding Konferensi IEEE 2009 tentang Computer Vision and Pattern Recognition, Miami, FL, AS, 20–25 Juni 2009; hlm. 248–255. [[Referensi silang](#) Bahasa Indonesia]
52. Russakovsky, O.; Deng, J.; Su, H.; Krause, J.; Satheesh, S.; Bu, S.; Huang, Z.; Karpaty, A.; Khosla, A.; Bernstein, M.; dkk. Tantangan Pengenalan Visual Skala Besar ImageNet. *Jurnal Int. Komputer.***Tahun 2015**Bahasa Indonesia: 115, hal. 211–252. [[Referensi silang](#) Bahasa Indonesia]
53. Deng, J.; Russakovsky, O.; Krause, J.; Bernstein, MS; Berg, A.; Fei-Fei, L. Anotasi Multilabel yang Dapat Diskalakan. Dalam *Prosiding Konferensi SIGCHI tentang Faktor Manusia dalam Sistem Komputasi*, ACM: New York, NY, AS, 2014. [[Referensi silang](#) Bahasa Indonesia]

54. Zhang, Q.; Yang, S.; Ren, R. Penelitian tentang Sistem Buku Teks Digital Lintas Platform Berbasis Uni-app. Dalam Prosiding CSSE 2020: Konferensi Internasional ke-3 tentang Ilmu Komputer dan Rekayasa Perangkat Lunak 2020, Beijing, Tiongkok, 22–24 Mei 2020. [[Referensi silang](#) Bahasa Indonesia]
55. Voron, F. *Membangun Aplikasi Ilmu Data dengan FastAPI: Mengembangkan, Mengelola, dan Menyebarkan Aplikasi Pembelajaran Mesin yang Efisien dengan Python*; Packt Publishing Ltd.: Birmingham, Inggris, 2023.

Penafian/Catatan Penerbit: Pernyataan, opini, dan data yang dimuat dalam semua publikasi merupakan milik masing-masing penulis dan kontributor, bukan milik MDPI dan/atau editor. MDPI dan/atau editor tidak bertanggung jawab atas segala cedera yang dialami orang atau harta benda akibat ide, metode, instruksi, atau produk yang dirujuk dalam konten.